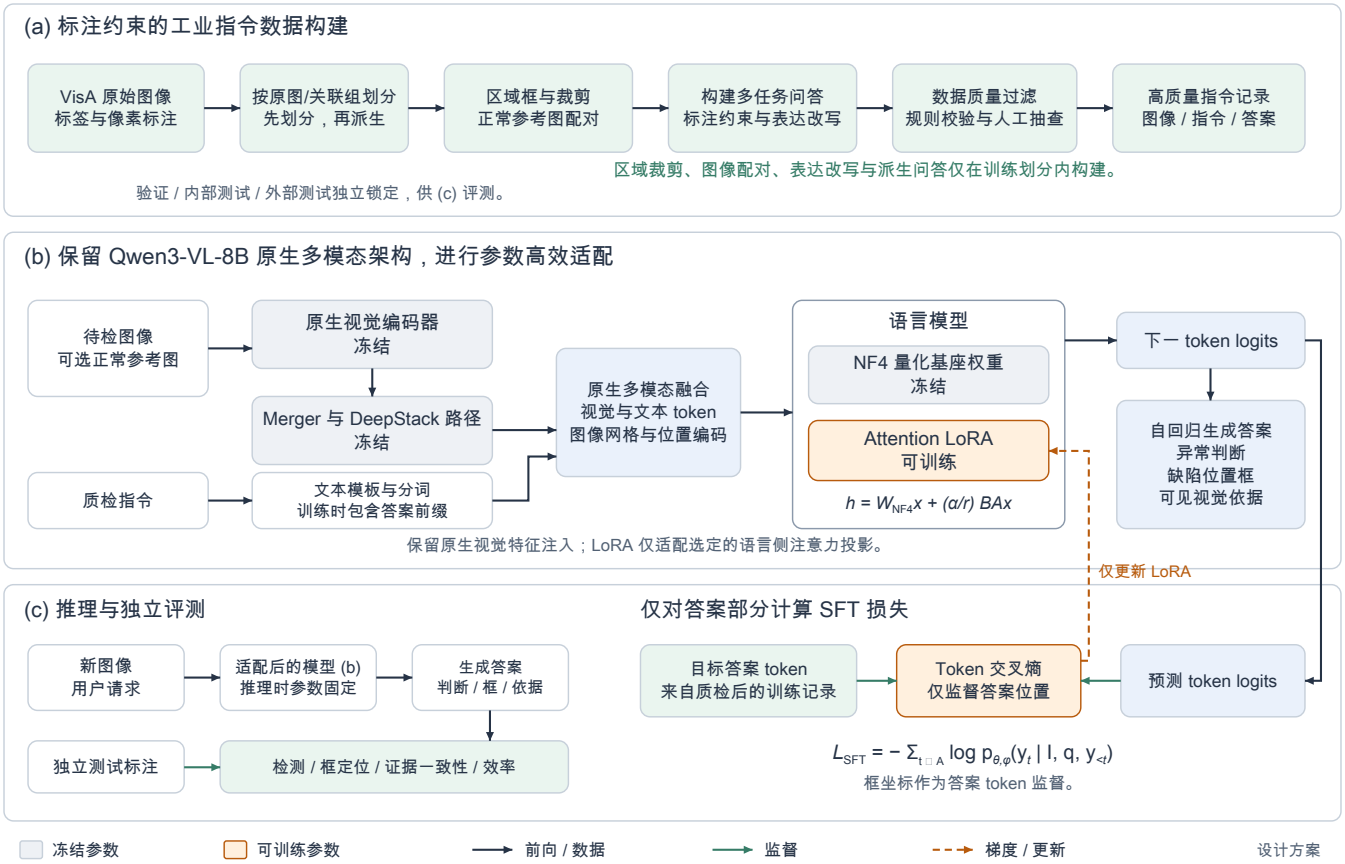

(a) 标注约束的工业指令数据构建
VisA 原始图像
标签与像素标注
按原图/关联组划分
先划分，再派生
区域框与裁剪
正常参考图配对
构建多任务问答
标注约束与表达改写
数据质量过滤
规则校验与人工抽查
高质量指令记录
图像 / 指令 / 答案
区域裁剪、图像配对、表达改写与派生问答仅在训练划分内构建。
验证 / 内部测试 / 外部测试独立锁定，供 (c) 评测。
(b) 保留 Qwen3-VL-8B 原生多模态架构，进行参数高效适配
待检图像
可选正常参考图
原生视觉编码器
冻结
Merger 与 DeepStack 路径
冻结
质检指令
文本模板与分词
训练时包含答案前缀
原生多模态融合
视觉与文本 token
图像网格与位置编码
语言模型
NF4 量化基座权重
冻结
Attention LoRA
可训练
h = W_NF4x + (α/r) BAx
下一 token logits
自回归生成答案
异常判断
缺陷位置框
可见视觉依据
保留原生视觉特征注入；LoRA 仅适配选定的语言侧注意力投影。
仅更新 LoRA
(c) 推理与独立评测
新图像
用户请求
适配后的模型 (b)
推理时参数固定
生成答案
判断 / 框 / 依据
独立测试标注
检测 / 框定位 / 证据一致性 / 效率
仅对答案部分计算 SFT 损失
目标答案 token
来自质检后的训练记录
Token 交叉熵
仅监督答案位置
预测 token logits
L_SFT = − Σ_{t∈A} log p_{θ,φ}(y_t | I, q, y_<t)
框坐标作为答案 token 监督。
冻结参数
可训练参数
前向 / 数据
监督
梯度 / 更新
设计方案