v1 Patch9 图像分割模型架构

冻结 Qwen3-VL 视觉特征 + 可训练多尺度 mask decoder + Patch9 推理融合

(a) 训练阶段：像素级监督的分割解码器

训练样本构造

异常整图 I^{full}
非空 Y^{full}

含缺陷正样本 patch I_k^+
非空 Y_k^+

正常整图 I^0
空 mask $Y^0=0$

图像预处理
448×448 RGB
28×28 patch 网格

Qwen3-VL-2B
视觉编码器
冻结

H^5, H^{11}, H^{17}
多层深度特征
$28\times28\times h_v$

空间恢复
$H^l \to F^l$
$h_v\times28\times28$

特征适配器
1×1 Conv + GN + GELU
3×96 → 拼接 288 通道

共享特征

残差融合模块
2 个残差卷积块
$Z\in R^{288\times28\times28}$

掩码头（Mask Head）
1×1 Conv
1×28×28

上采样
448×448

概率 mask P
$\sigma(S)\in[0,1]^{448\times448}$

loss

监督目标 Y：448×448
$L=L_{Focal}(\gamma=2,\alpha=.25)+L_{SoftDice}$
反向传播只进入可训练 decoder

紫色边框：可训练（约 3,285,505 参数）

蓝色边框：冻结；语言塔、虚拟提示学习器、区域头在 v1 segmentation_only 中不参与前向

(b) 推理阶段：Patch9 融合、分类器门控与最终输出

测试输入

一个测试视角 I
原始分辨率

Patch9 生成器
整图 + 9 个重叠 patch

每个输入 → 448×448

共享 v1 分割器（权重复用 ×10）

冻结 Qwen3 视觉塔
+ 可训练 decoder
与训练阶段相同

$P_{full}, P_1, \ldots, P_9$
10 张概率图

独立图像分类器模型权重

Qwen3 视觉特征
投影/融合 + 虚拟提示词
视觉塔、语言塔冻结

异常概率 p_{img}

坐标逆映射 π
patch 回投原图
$\text{mean}_{w=0.5}$ 融合

融合概率图 P_{fuse}
软 mask
448×448

门控 $G(p_{img})$
$p<\tau$：输出全零 mask
$p\geq\tau$：保留融合 mask

最终视角 mask M
$M=G(p)\odot P_{fuse}$
448×448 灰度软 mask

五视角组分数
$s_{group}=max_{j=1\ldots5}p_j$

历史 v1 stitching 使用中心加权 max；统一消融报告固定为 $\text{mean}_{w=0.5}$。

$\tau=0.5$：带门控；$\tau=0$：无门控

冻结模块　可训练模块　操作 / loss　输出张量